

1차시 통계학이란?

1. 들어가며

여론조사 기관이나 신문기사에서 발표하는 조사 결과를 보면 표본오차나 신뢰수준이라는 단어가 등장한다. 다음의 예를 살펴보자.

【예제】

KBS에서 실시한 여론조사 결과
 A 후보 45.6%, B 후보 30.0%
 조사 기관 : 미디어리서치
 조사 시기 : 2006년 4월 27일~29일
 조사 대상 : 서울 거주 만 19세 이상 성인 남녀 1,000 명
 조사 방법 : 전화 면접 조사 (CATI: Computer Aided Telephone Interview)
 표본 오차 : $\pm 3.10\%$ 포인트 (95% 신뢰수준)

【예제】

승용차 10부제에 관한 여론 조사를 실시한 결과 10부제에 대한 찬성률이 53%로 나타났다.
 이 조사의 신뢰 수준은 95%이며 오차는 $\pm 5\%$ 포인트이다.

여론조사 결과에 항상 등장하는 신뢰수준은 무엇이며, 오차는 어떤 의미일까? 신뢰수준 95%에서 95%가 의미하는 바는 무엇일까? 이를 정확하게 이해하기 위해서는 통계학의 기초지식이 필요하다.

2. 통계학의 필요성

2.1 통계학의 매력

2019년 최고의 직종은? 구인·구직 기반 사회관계망서비스(SNS) 링크드인은 최근 자사의 데이터를 바탕으로 2019년 미국 최고 유망 직종을 발표했다. 1위는 데이터 과학자로, 데이터 과학자에게 요구되는 주요 기술로는 데이터 과학, 데이터 마이닝(Data Mining), 데이터 분석(Data Analysis), 파이썬(Python·프로그래밍 언어), 기계 학습(Machine Learning) 등이 있다. 이 중에서도 통계학은 데이터 과학자가 지녀야 할 필수지식이라고 할 수 있다.

Rank	2018	2019
1	Engagement Lead	Data Scientist *
2	Software Engineering Manager	Site Reliability Engineer
3	Customer Success Manager	Enterprise Account Executive
4	Solutions Architect	Product Designer
5	Sales Director	Product Owner
6	Engineering Manager	Customer Success Manager
7	Program Manager	Engagement Manager
8	Product Manager	Solutions Architect
9	Data Scientist *	Information Technology Lead
10	Enterprise Account Manager	Scrum Master

빅데이터 시대가 되면서 데이터 분석에 대한 수요가 늘고, 이미지, 센서, 텍스트 등의 다양한 자료들이 생성되면서 금융, 경제, 보건, 의료 등의 다양한 분야에서 통계학이 활용되고 있다.

미래의 불확실성에서 빠르게 변화하는 환경에서 효과적인 예측과 의사결정을 위해서는 필요한 자료와 정보를 수집하고 정리하고 표현하는 기법을 습득할 필요가 있다. 특히, 컴퓨터의 기술 발달로 빠르고 효율적인 분석이 가능해지면서 통계학의 중요성과 필요성은 강조되고 있다.

2.2 통계학을 배워야 하는 이유

우리가 통계학을 배워야 하는 첫 번째 이유는 매일 접하는 정보와 숫자 속에서 이를 이해하고 이용할 줄 알아야 하기 때문이다. 앞서 설명한 예처럼, 국민적 관심의 대상이 되는 이슈가 발생할 때, 국회의원 및 대통령 선거가 있을 때 각 언론에서 여론조사를 실시하여 발표함으로써 여론의 흐름을 판단할 수 있도록 도와준다. 이때, 표본크기, 허용오차, 신뢰수준 등을 밝히는데 이러한 용어의 의미를 이해하기 위해서는 통계학의 개념에 대한 이해가 필요하다. 때로는 수집된 자료를 차트나 그래프로 표현하기도 하는데 이를 읽고 해석하기 위해서는 통계학의 기초를 배워야 한다.

두 번째로, 우리는 일상생활에 영향을 미치는 의사결정을 할 때 통계적 기법과 도구를 사용하기 때문이다. 예를 들어, 국내 소방펌프차량의 배치를 설계한다고 할 때, 현재 인구와 소방대상물의 정보를 이용하여 소방펌프차수를 예측한 다음, 과소, 과대 배치되어 있는 구역을 확인하고 이를 재조정할 수 있다. 이러한 의사결정 과정에서 필요한 자료와 정보를 분석하고 이용하려면 통계학이 필요하다.

세 번째로, 통계방법을 알고 있으면 어떤 결론이 어떻게 도출되었으며 이것이 우리에게 어떤 영향을 미칠 것인지 이해하는 데 도움이 되기 때문이다. 예를 들어,

- 신약이 혈압을 낮추는데 효과가 있을까?
- 대학 입학에 남녀의 성차별이 있을까?
- 비싼 와인이 더 맛있을까?

위와 같은 질문에 대한 답을 하기 위해서는 어떤 데이터를 가지고 어떠한 분석을 해야 되는지를 고민하게 되는데 통계학은 신뢰할 수 있는 자료를 어떻게 생성할 수 있을지, 어떤 분석방법이 적절한지에 대한 해결방안을 줄 수 있다.

3. 통계학의 활용 및 적용 분야

3.1 통계로 생명을 구하다

통계학의 활용은 오늘날의 이야기가 아니다. '간호사'의 대명사인 나이팅게일은 사실은 위대한 통계학자였다. 나이팅게일은 1820년 이탈리아 피렌체에서 태어났다. 부유한 영국 중산층이었던 부모 밑에서 부유하게 자란 그녀는 어린 시절부터 숫자로 각종 정보를 정리하는 일을 즐겼다. 유럽으로 가족 여행을 갈 때, 매일 여행한 거리를 계산하고, 출발 및 도착 시간을 기록했으며, 여행한 지방의 법률과 토지관리체계, 복지기관들을 관찰해 통계를 냈다.


이처럼 수와 통계에 관심이 많던 그녀는 스무 살 때, 개인 수학 교사를 두고 수학을 정식으로 배워 전문적인 통계학적 지식을 배우기도 했다. 이후 1851년 이집트 여행 도중 알렉산드리아 병원을 방문하게 되고, 정규 간호 교육의 필요성을 느끼고, 독일 간호학교에 입학하고 1853년 런던 숙녀병원의 간호부장이 되었다.

간호부장이 된 그 다음해 크림전쟁이 발발하자 나이팅게일은 아전간호활동을 하게 되는데, 당시 아전 병원은 매우 불결했다. 실제로 당시 전투에서 전사한 병사의 수보다 치료 도중 사망한 병사의 수가 훨씬 많았다. 환자의 사망률은 42%에 육박하였다.

나이팅게일은 아전병원의 위생을 개선하기 위해선 아전병원의 상황에 대한 통계가 필요하다고 생각했다. 아전병원의 위생을 개선하기 위해 입원/부상/질병/사망 등의 내역을 본인이 만든 작성기준에 따라 모든 내역을 상세히

기록했고, 이 기록을 토대로 보고서를 작성하여 영국 정부에 보냈다. 나이팅게일이 보낸 보고서를 확인한 영국 정부는 야전병원의 위생을 대폭 개선하기 위한 조치를 취하게 된다.

나이팅게일이 제시한 통계는 높은 위생수준이 부상자들을 살린다는 증거가 되었고, 수많은 사람들을 설득할 수 있는 유용한 자료가 되었다. 대대적인 위생 개선이 이루어진지 한 달 만에 사망률이 급격하게 떨어졌고, 6개월 후 환자 사망률은 42%에서 2%로 급락하게 된다. 이렇듯, 나이팅게일은 통계학을 이용해 수많은 병사들의 생명을 구한 것이다. 이후, 나이팅게일은 1858년 영국왕립통계학회에 최초의 여성 회원으로 선출되었다.



3.2 일상생활 속의 통계학

통계학은 일상생활에도 활용되는데, 그 중 하나가 일기예보이다. 날씨를 예보할 때 “내일 비올 확률이 40%”라는 말을 들어보았을 것이다. 확률이란 어떤 사건이 일어나는 가능성의 정도를 나타내는 것으로, 일기예보 중 강수량을 예보할 때 강수 확률로 나타낸다. 비 올 확률이 40%라는 의미는 내일의 조건과 비슷한 조건인 10일 중 4일이 강수가 있을 것이라는 뜻이다. 즉, 일기 예보는 과거의 통계자료를 기초로 산출하는 것으로 강수확률 40%는 현재와 같은 기상 상태가 반복된다고 가정할 때 약 40%의 경우에는 비가 온다는 것을 의미한다.

이처럼, 오늘날 자료의 수집과 분석에 통계적 방법이 이용되는 분야는 일일이 열거할 수 없을 정도로 많다. 앞서 설명한 일기예보, 여론조사, 흡연의 위생성 분석, 제품의 품질 향상 등에서 통계학은 중요한 역할을 담당하고 있다. 이 외에 우주선 발사에서 시스템의 안전도 검사, 석유탐사 시 매장성분과 매장량의 추측, 해저 광맥의 탐사 등에도 통계학이 이용된다. 최근에는 인간 외의 구조 분석을 통한 인공지능 소프트웨어의 개발에도 통계학이 활용되고 있다. 환경과 관련해서는 지구의 이상변화에 대한 원인 분석 및 대처 방안의 효율성 비교에도 통계학은 큰 역할을 하고 있다.

4 통계학의 기본개념 및 주요용어

4.1 통계학의 기본개념

통계학의 기본개념을 이해하기 위해서는 먼저 모집단과 표본의 개념을 이해해야 한다. 우선, 누구나 익숙한 여론조사 예를 가지고 통계학의 기본개념을 이해하도록 하자.

【예제】

다음 자료는 어느 대통령 선거 전에 여론조사 기관에서 조사한 유권자의 지지성향에 대한 여론조사 결과이다.
표 1.1. 대통령 선거 전 어느 여론조사 결과

후보자	A후보	B후보	C후보	D후보	E후보	기타
지지율	41.8%	21.2%	19.4%	3.9%	8.7%	5.0%

이와 같은 여론조사의 목적은 전체 유권자의 각 후보에 대한 지지율과 더 나아가서는 연령별, 지역별 유권자의 지지성향을 알아보는 것이다. 그러면 여론조사의 실시과정을 살펴보면 여론조사 시 고려해야 할 사항에 대해 몇 가지 살펴보고자 한다.

첫 번째는 여론조사 기관에서 가장 먼저 고려해야 할 사항은 전체 유권자 중에 몇 명의 유권자를 어떻게 선정하는 것에 대한 문제이다. 전체 유권자를 조사하는 것은 시간적이나 경제적인 측면 등으로 볼 때 거의 불가능하고 불합리적이기 때문이다. 이 때 고려해야 할 사항은 조사 대상으로 선정된 유권자가 전체 유권자의 성향을 대표할 수 있어야 한다. 특히, 연령별, 지역별로 지지성향을 파악하고자 할 때는 연령별, 지역별로 유권자가 골고루 뽑혀야 할 것이다.

두 번째는 조사한 내용을 어떻게 요약하고 이를 바탕으로 전체 유권자의 성향을 어떻게 결론을 내릴 것인가 하는 문제이다. 예를 들어, 표1에서의 여론조사 결과를 보면 B후보가 C후보를 다소 앞서고 있는데, 전체 유권자에서도 B후보가 지지율이 더 높다고 결론을 내릴 수 있는지의 문제이다.

마지막으로는 이와 같은 결론이 항상 사실과 일치할 수 없고, 또한 다른 여론조사 결과는 위와 다를 것이다. 즉, 다른 기관에서 다른 유권자들을 대상으로 조사를 한다면 표1과는 다른 결과가 나올 것이다. 그렇다면 한 여론조사 결과의 신뢰성을 어떻게 측정할 것인가 하는 문제이다.

통계학(statistics)이란? 이와 같이 주어진 문제에 대하여 합리적인 답을 이끌어내기 위해 숫자로 표시되는 정보(자료:data)를 수집·정리하고 분석하며 이를 해석하고 신뢰성 있는 결론을 이끌어내는 일련의 과정을 연구하는 학문이다. 통계학의 주된 과제는

- 자료를 수집하는 방법
- 자료를 분석하는 방법
- 자료로부터 얻은 결론에 대한 객관성을 보장하는 방법

다음으로 통계학에서 기본적으로 알아야 할 주요용어인 모집단과 표본, 모수와 통계량에 대해 알아보자.

- 모집단(population)이란? 주어진 문제에서 관심의 대상이 되는 전체집단을 말하며, 여론조사 예에서는 대통령 선거의 유권자 전체를 의미한다.
- 표본(sample)은 모집단의 특성을 파악하기 위해 추출된 모집단의 일부를 말하며, 여론조사 예에서는 선정된 조사대상자를 의미한다.
- 모수(parameter)는 모집단의 특성을 나타내는 수이며, 예에서는 전체 유권자에 대한 각 후보의 실제 지지율을 나타낸다.
- 통계량(statistic)은 모수를 추정하기 위한 표본의 특성을 나타내며, 예에서는 표1에서와 같이 표본으로부터 계산된 각 후보의 지지율을 나타낸다. (정확히 말하면, 표본으로부터 각 후보의 지지율을 구하는 방식을 통계량이라 하며, 표1과 같이 표본으로 계산된 구체적인 값을 통계치(statistics)라 한다. 통계량과 통계치의 명확한 구분은 다음에 설명하도록 한다).

모집단의 용어를 좀 더 살펴보면, 모집단은 관심의 대상이 되는 전체집단을 의미하는데, 여기에서 전체를 구성하는 각 개체를 추출단위(sampling unit)라 하며, 추출단위가 유한인 경우 유한모집단(finite population)이라 하며, 추출단위가 무한인 경우를 무한모집단(infinite population)이라 한다. 모집단의 크기는 연구자가 정하는 연구대상의 범위에 따라 결정되는 것이다. 예를 들면,

- A대학교의 대학생의 용돈의 평균에 관심 있으면 모집단은 A대학교의 전체 대학생으로 유한모집단이라 할 수 있고,
- 어느 생산 공정에서 생산되는 제품의 수명에 관심이 있으면 제품은 공정에서 계속 생산된다고 간주하면 무한모집단이라 할 수 있다.

4.2 자료 분석의 목적에 따른 분류

통계학은 자료 분석의 목적에 따라 크게 두 가지로 분류할 수 있는데 하나는 기술통계학이고, 다른 하나는 추측 통계학이다. 우리는 어떤 문제에 대해 방대한 자료를 수집하였을 때, 그 자체만으로는 의미 있는 정보를 얻기 힘들다. 따라서 이러한 자료를 정리·요약·표현·분석함으로써 모집단의 특성을 규명하고 의사결정을 할 수 있는 정보를 얻을 수 있다. 얻어진 자료를 단순히 설명·묘사하기 위해서는 기술통계학을, 더 나아가 얻어진 자료의 결과를 일반화하기 위해서는 추측통계학을 알아야 한다.

- 기술 통계학(descriptive statistics): 자료를 수집하고 정리하여 도표나 표를 만들거나 자료를 요약하여 대표값이나 변동의 크기 등을 구하는데 중점을 둔 통계학(본 강좌의 앞부분에 배울 것이며 자료의 요약 및 시각화 부분이 이에 해당된다)

【예제】

소비자 물가지수, 실업률 등은 기술통계학을 이용한 결과

- 추측 통계학(inferential statistics): 모집단으로부터 추출된 표본의 정보를 바탕으로 모집단의 어떤 특성에 대해 예측하거나 밝히는데 둔 통계학(본 강좌의 뒷부분에 배울 것이며 추정과 검정 부분이 이에 해당된다)

【예제】

여론조사에서 각 후보의 지지도를 조사한 후 특정 후보의 당선 가능성을 예측하거나 신뢰성을 바탕으로 추론

4.3 자료를 이용한 의사결정과정

요약하면, 어떤 주어진 문제에 대해 통계학을 적용하여 자료를 이용한 의사결정과정은 다음과 같이 도식화 할 수 있다.

- 원리1: 모집단으로부터 표본을 뽑고 필요한 것을 조사하여 표본의 특성을 기초로 모집단의 특성을 아는 것이 통계적 분석의 기본적인 방식
- 원리2: 표본을 뽑을 때 모집단의 특성이 잘 나타나게끔 치우치지 않게 뽑을(랜덤하게) 필요가 있다.

