

3차시 자료의 이해와 시각화 (1)


1. 자료의 이해

통계학은 자료를 다루는 학문이다. 주어진 문제에서 통계학을 적용하기에 앞서 자료에 대한 충분한 이해가 있어야 하고, 자료의 속성도 정확히 파악해야 적절한 통계분석 방법론을 적용할 수 있다. 통계분석방법은 자료의 속성과 분석 목적에 따라 달라지며 분석방법을 적용하기 위한 조건이 있다. 이번 차시에서는 자료를 속성에 따라 어떻게 분류하는지 알아본다.


자료(data)란 변동(variation)을 표현하는 중요한 수단(언어)으로 좁은 의미에서는 숫자들을 모아놓은 집합이다. 최근 빅데이터 시대에서는 다양한 형태(비정형화)의 자료가 쏟아져 나오고 있으며 이러한 비정형화된 자료(unstructured data)를 분석하려는 요구가 날이 증가하고 있다. 예를 들면, 이미지 자료(image), 보이스 자료(voice), 텍스트 자료(text)가 이에 해당된다. 이러한 비정형화된 자료도 자료의 범주에 포함하며 최근에는 통계학의 분석 대상이다. 여기에서 기억해야 할 점은 아무리 비정형화 되어 있는 자료라고 할지라도 분석을 위해서는 각종 전처리 작업을 통해 자료를 정형화시켜 숫자들의 집합으로 만드는 것이다.

예를 들면, [예시 1]에서 볼 수 있듯이 이미지는 기술적으로 단위 당 비트 수 (표시하는 색의 수를 정의하는 색 깊이)로 구분된다. 각 화소는 RGB 색 공간에서 개별적으로 정의된 색, 그림을 가지고 있다. 또 다른 예인 음성 자료는 고유의 주파수와 진폭으로 이루어져 있기 때문에 이를 이용해 디지털 자료로 변환할 수 있다. 텍스트 자료의 경우 [예시 3]에서 보는 바와 같이 전체 문서 집합을 하나의 수치화된 행렬(단어-문서행렬)로 변환하여 분석을 수행할 수 있다.

구체적으로 말하면, 단어-문서행렬의 각 열은 하나의 문서를 지칭하며 각 열에서의 값은 특정한 단어가 나온 빈도를 나타낸다. 이를 통해 단어 및 문서간의 연관성 등 텍스트 자료로부터 다양한 의미 있는 분석 할 수 있다. 가장 간단한 텍스트 자료의 분석으로 [예시4]와 같은 단어구름을 볼 수 있다. 2012년 어느 대통령 선거 대선후보 TV토론의 텍스트 자료로부터 나온 각 단어에 빈도를 부여하고, 단어의 빈도수에 따라 단어의 크기를 다르게 하여 보여주는 단어구름을 통해 보여줌으로써 이 대선후보가 강조하는 공약의 키워드를 시각적으로 파악할 수 있게 해준다.



[예시 1] 래스터 그래픽스



[예시 2] 음성 데이터 변환



Vector-space representation

	D1	D2	D3	D4	D5
complexity	2		3	2	3
algorithm	3			4	4
entropy	1			2	
traffic		2	3		
network		1	4		

Term-document matrix

as scoring ...



[예시 4] 2012년 대통령 선거 대선후보 TV토론의 텍스트 자료로 부터의 단어구름

이와 같이 빅데이터 시대에서는 단순히 숫자들의 모임 이외에도 이미지, 보이스, 텍스트 자료 등으로 자료의 범위를 넓게 보고 있고, 이전의 정형화된 데이터(숫자들의 직사각형 모임) 뿐만 아니라 다양한 형태의 비정형화 된 데이터로부터 가치 있는 정보를 추출하려는 노력이 계속 진행되고 있다.

2. 자료의 종류

2.1 자료의 속성에 따른 분류

일반적으로 자료는 그 속성에 따라 크게 숫자에 의미가 있는지 없는지에 따라 양적자료와 질적자료로 나눌 수 있다. 양적자료는 다시 연속형자료와 이산형자료로 나눌 수 있고, 질적자료는 순서에 의미가 있는지 없는지에 따라 명목형 자료와 순서형 자료로 다음과 같이 나눌 수 있다.

- (1) 양적자료(quantitative data): 수치로 나타낼 수 있는 자료
 - 이산형자료(discrete data): 관측값들을 셀 수 있는 자료
(예) 교통사고 건수, 자녀수, 에어컨 생산대수 등
 - 연속형자료(continuous data): 관측값들을 셀 수 없고 연속적인 구간의 값을 갖는 자료
(예) 신장이나 체중, 체질량지수, 소득, 예금 잔액 등
- (2) 질적자료(qualitative data): 원칙적으로 수치로 표현될 수 없고 어떤 속성(범주)을 나타낸 자료로 범주형자료(categorical data)라고도 함.
 - 명목형자료(nominal data): 순서에 의미가 없는 자료
(예) 성별(남/여), 혈액형(A형/B형/O형/AB형), 생존여부 등
 - 순서형자료(ordinal data): 순서에 의미가 있는 자료
(예) 순위(1등, 2등, 3등), 학점(A학점/B학점/.../F학점), 비만도(과체중/보통/저체중) 등

위와 같은 자료의 속성에 따라 자료를 요약 정리하는 방법이 다르고, 통계분석방법도 달라진다. 따라서 자료가 주어지면 통계분석을 하기 전에 각 자료의 속성을 정확히 파악할 수 있어야 한다.

2.2 변수의 수에 따른 분류

변수(variable)란? 조사대상 혹은 관찰개체에 대한 관심이 되는 특성을 나타낸다. 예를 들면, 조사대상이

- 사람일 경우 변수는 키, 몸무게, IQ, 수입, 학력 등
- 기업일 경우 변수는 매출액, 종사자수, 자본금, 주가 등
- 꽃일 경우 변수는 꽃잎의 너비, 줄기의 길이, 뿌리의 길이 등

자료를 변수의 개수에 따라 다음과 같이 분류할 수 있다.

1. 일변량 자료(univariate data): 조사 혹은 관찰대상이 되는 각 기본단위가 하나의 변수(단변수)를 가질 때 이를 측정하여 얻는 자료
 - 일변량 자료는 변수가 하나이기 때문에 자료의 대표치, 기본단위들의 동질성, 이상치의 존재여부 등에 관한 특성을 요약하는 기본적인 통계분석방법이 사용됨
2. 이변량 자료(bivariate data): 두 개의 변수를 함께 관찰하여 얻는 자료
 - 각 변수의 특성(일변량 분석) 이외에도 두 변수간의 관계에 대해 파악할 수 있다.
 - 예를 들면, 각 조사대상에 키와 몸무게를 같이 조사하여 얻은 이변량 자료를 가지고, 모집단의 키와 몸무게의 평균을 추정할 수 있고, 또한 키와 몸무게 간의 관계도 파악할 수 있다.
3. 다변량 자료(multivariate data): 여러 개의 변수(다변수)로 이루어진 자료
다변량 자료는 각 기본단위에 변수가 두 개 이상이므로 일변량 자료에서 얻는 특성 외에 변수간의 관계, 변수간의 밀접성, 한 변수의 값이 주어질 때 다른 변수의 값에 대한 예측 등을 밝히는 통계분석이 사용될 수 있다.

일반적으로 자료는 다변량 자료이며 각각의 관심 있는 변수에 따라 통계분석을 수행할 수 있다. 특정 관심 변수에 대한 분석을 할 때, 그 변수만을 사용하여 분석을 하면 일변량 분석이라 하며, 그 변수 이외의 다른

변수들의 관계를 고려하여 같이 분석을 하면 다변량 분석이라 한다. 예를 들면, 상위 100대 기업의 매출액에 관심이 있을 때,

- 일변량 분석: 100대 기업의 매출액의 평균, 분산, 중위수, 분위수 등을 매출액 변수자체만을 가지고 분석할 경우
- 다변량 분석: 매출액에 영향을 미치는 다른 변수(기업규모, 주가, 투자금 등)를 고려하여 분석할 경우

2.3 자료의 목적에 따른 분류

연구자는 연구의 목적을 달성하기 위해 자료를 수집해야 한다. 자료는 연구자가 연구문제의 해결을 위해 직접 수집하는 1차 자료와 다른 사람이나 기관에서 수집하여 공개적으로 이용할 수 있는 2차 자료로 구별할 수 있다. 다음 표는 1차자료와 2차자료의 정의 및 장단점을 정리한 표이다.

	1차자료	2차자료
정의	연구자가 연구의 목적을 달성하기 위해 직접 수집한 자료	연구자가 연구의 목적에 맞게 모은 기존의 모든 자료
장점	- 연구목적에 부합하는 자료를 수집할 수 있음 - 의사결정이 필요한 시기에 적절히 이용가능(시의성)	시간, 비용, 인력이 적게 소요됨
단점	시간, 비용, 인력이 많이 소요됨	- 연구목적에 정확히 부합하는 자료를 찾기 어려움 - 현재 의사결정 문제에 적절한 정보를 제공하지 못할 수 있음(시의성)
예시	관찰법, 실험법, 면접법	문헌조사, 기존조사의 통계표

2.4 전형적인 자료셋(dataset): 자료행렬(data matrix)

다음은 어느 대학교의 교양과목에 대한 학생들의 성적을 나타내는 자료이다.

성명	학과	학년	성별	중간고사	기말고사	재이수여부
홍길동	통계학과	2	M	98	88	
성춘향	경제학과	2	F	92	85	
김영희	수학과	1	F	88	74	
김철수	통계학과	3	M	94	76	재이수
...	...	...	...	...	...	...

위와 같이 각 관심의 대상에 대한 변수들의 자료를 모아 놓은 것을 데이터셋(dataset) 혹은 자료행렬(data matrix)라 한다. 일반적으로 자료행렬에서 행은 각 관찰대상을 나타내고, 열은 각 변수를 나타낸다. 여기에서,

- 관찰대상은 각 학생을 나타내고, (case, individual, sample 등 용어를 사용)
- 변수는 학과, 학년, 성별, 성적 등을 나타냄 (variable, feature 등 용어를 사용), 여기에서 변수는 양적변수와 질적변수로 나눌 수 있음.
 - 양적변수(quantitative variable): 중간고사, 기말고사 (연속형)
 - 질적변수(qualitative variable): 학과, 성별, 재이수 여부는 명목형이고, 학년은 순서형임.

2. 질적자료의 요약 및 시각화

정리되지 않고 수집된 자료의 전체적인 특성이나 구조를 파악하기 위해서는 자료를 정리하고 요약해야 한다. 기본적으로 자료를 정리할 때 많이 쓰이는 방법은 도수분포표가 있고, 이를 바탕으로 질적자료에서는 막대그래프와 원그래프, 연속형 자료에서는 히스토그램을 통해 자료의 전반적인 개형이나 분포를 파악할 수 있게 한다.

2.1 막대그래프와 원그래프

막대그래프와 원그래프는 질적 자료의 특징을 파악하기 위해서 작성하는 그래프이다. 막대그래프는 표현 값에 비례하여 높이와 길이를 지닌 직사각형 막대로 범주형 데이터를 표현하는 차트나 그래프를 말한다. 막대그래프를 그릴 때에는 빈도 또는 백분율을 이용하여 일반적으로 빈도를 더 많이 사용한다. 원그래프는 전체에 대한 각 부분의 비율을 부채꼴 모양으로 나타낸 그래프이다. 항목(값)이 5개 이하인 경우에 적당하며, 전체적인 비율을 한눈에 볼 수 있다는 장점이 있다.


[표 2.1]은 2016년도 교통사고 발생건수 자료에서 차량 종류 발생 건수를 정리한 도수분포표이다. 이를 막대그래프와 원그래프로 나타내보자.

[표 2.1] 교통사고 차량 종류


차량 종	빈도
건설기계	94
농기계	72
대형	478
소형	1265
자전거	113
총합계	2022

(1) 막대그래프

막대그래프에는 세로 막대그래프와 가로 막대그래프가 있다. 세로 막대그래프는 y축에, 가로 막대그래프는 x축에 축 제목을 표시하여 막대의 높이(또는 길이)가 무엇을 의미하는지 알 수 있도록 해준다.




[그림 1] 세로 막대그래프 예시



[그림 2] 가로 막대그래프 예시

(2) 원그래프


원그래프는 각 항목이 전체 중에서 얼마나 차지하고 있는지를 표현하는 데에 유용하다. 아래 [그림 3]은 교통사고가 발생한 차량의 종류를 원그래프로 표현하였다. 이 그래프를 통해 소형 차종의 사고 발생률이 가장 높음을 확인할 수 있다.



[그림 3] 원그래프 예시

2.2 잘못된 그래프 사례

다음은 막대그래프와 원그래프의 잘못된 사례이다. [그림3]은 막대그래프의 세로축을 조작하여 변화량을 과장하는 사례이고, 비슷하게 [그림4]는 원자료의 비율과 원그래프 영역의 크기가 다르도록 조작한 잘못된 사례이다.



[그림 3] 국가별 공휴일 현황



[그림 4] 대통령의 국정운영에 대한 평가의견

위와 같은 잘못된 그래프를 통한 결과에 현혹되지 않기 위해서는 그래프의 개형만을 보고 해석하는 것보다는 원자료의 수치를 꼭 확인하는 습관을 가져야 한다.